Atelier collecte de données

Confidential - Not for Public Consumption or Distribution

Problème business

- Besoin de surveiller la concurrence en tant que manager de centre commercial
- Connaitre les marques existantes dans les autres centres
- Surveiller les ouverture et fermeture de magasins
- Avoir une idée de la composition des centres des concurrents

Confidential - Not for Public Consumption or Distribution

Problème business

Exemple d'une liste de boutique sur un site de centre commercial

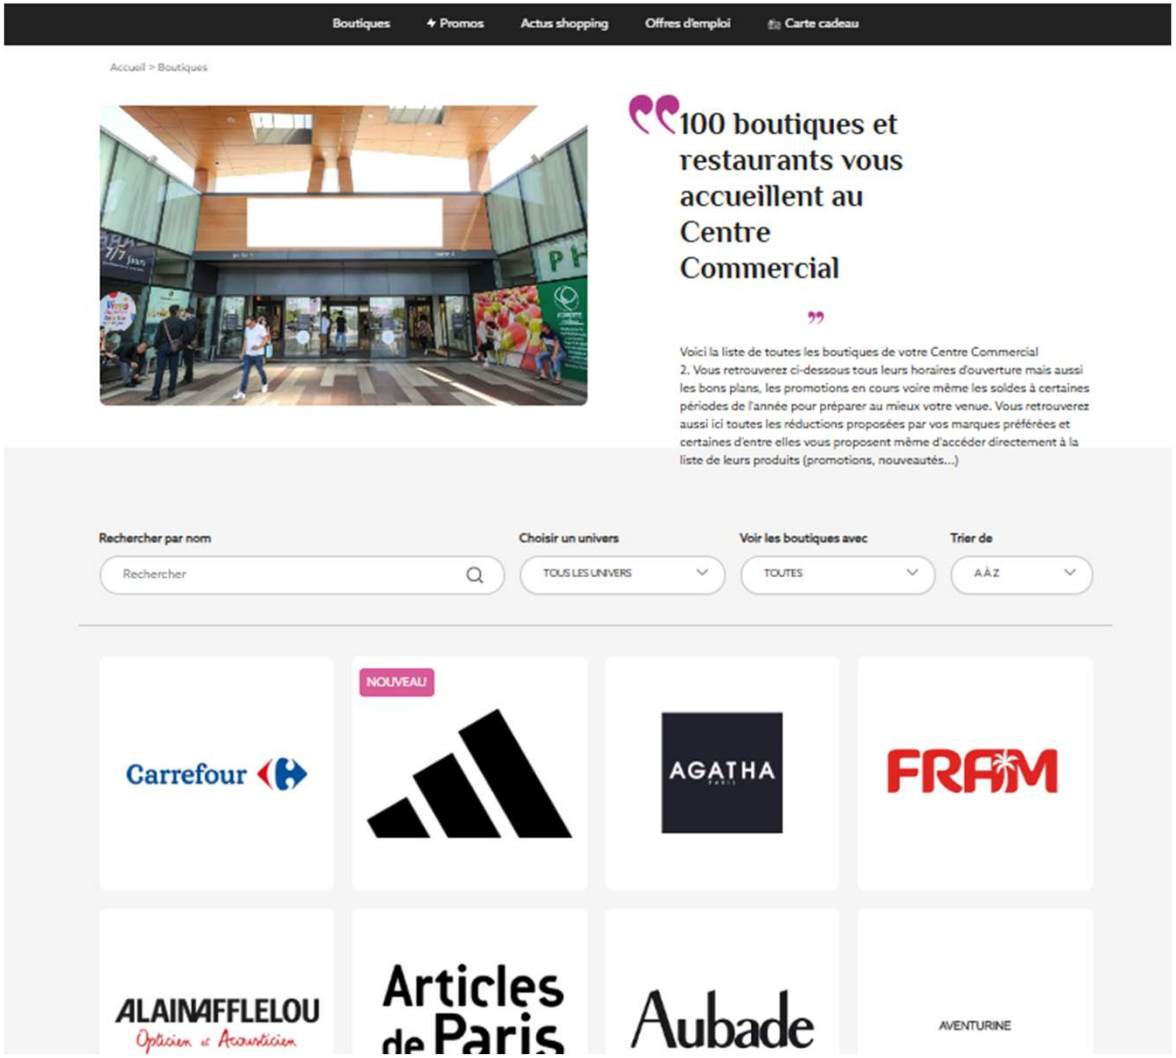

- Comment identifier les nouveaux magasins ?
- Comment avoir le nombre de magasin lié à la mode ?

Confidential - Not for Public Consumption or Distribution

Problème technique

- Pas de données BDD open source existante
- Pas d’API fiable
- Solution tierce trop couteuse

Confidential - Not for Public Consumption or Distribution

Objectif

- Créer une base de données des centres commerciaux européens avec leurs magasins et l’historique des ouvertures & fermetures

Confidential - Not for Public Consumption or Distribution

Solution envisagée

- Pipeline automatique d’ingestion de données par scraping

Confidential - Not for Public Consumption or Distribution

Fonctionnement site internet

- HTML (structure)
- CSS (design)
- JS (élément dynamique)

Confidential - Not for Public Consumption or Distribution

Fonctionnement site internet

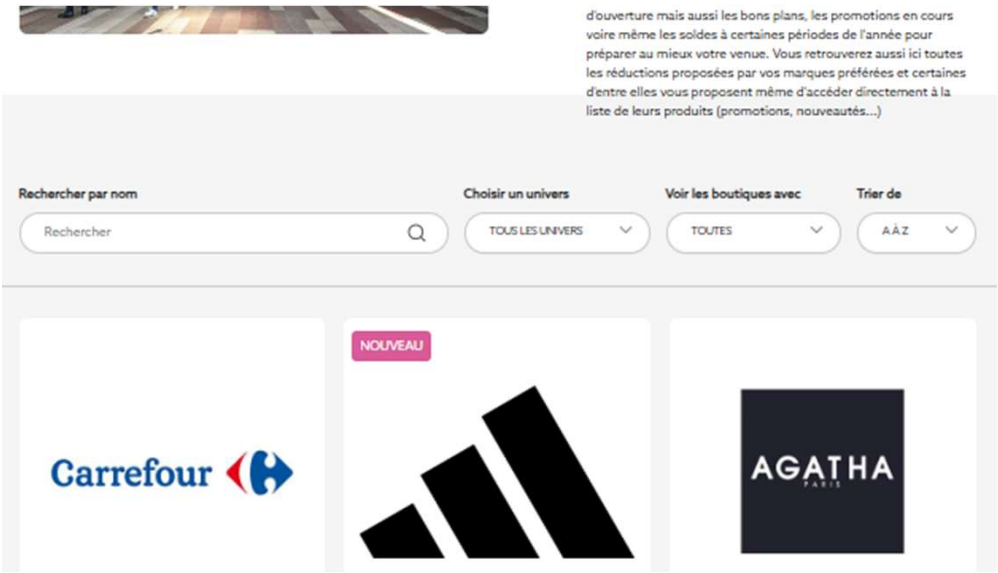

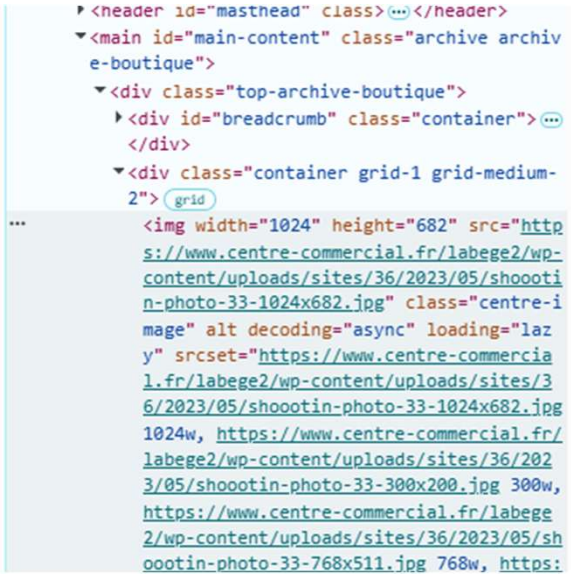

HTML

CSS

Confidential - Not for Public Consumption or Distribution

Récupération du code source

Statique

```python
import requests

url = "https://example.com"

response = requests.get(url)

html = response.text
```

Dynamique

```python
from selenium import webdriver

driver = webdriver.Chrome()
url = "https://example.com"
driver.get(url)
html = driver.page_source
driver.quit()
```

Confidential - Not for Public Consumption or Distribution

Parser et naviguer

Beautifulsoup

```python
from bs4 import BeautifulSoup

...

soup = BeautifulSoup(html, "html.parser")

container = soup.find("div", class_="container")
items = container.find_all("li", class_="item")

for item in items:
    print(item.text)

link = container.find("a")
print(link["href"])
```

selenium

```python
from selenium import webdriver
from selenium.webdriver.common.by import By

driver = webdriver.Chrome()

...

button = driver.find_element(By.ID, "accept-cookies")
button.click()

container = driver.find_element(By.CLASS_NAME, "container")

link = container.find_element(By.TAG_NAME, "a")
print(link.get_attribute("href"))

driver.quit()
```

Confidential - Not for Public Consumption or Distribution

Legal

- Respect du robots.txt
- Respect CGU / Copyright
- Données publiques et reglementation

Confidential - Not for Public Consumption or Distribution

Limitations

- Identification de la machine (user agent)
- Adresse IP
- Croisement des données du client (navigateur VS user agent VS IP VS langue)
- Comportement anormal
- Captcha

Confidential - Not for Public Consumption or Distribution

Instabilités

- Modification du site (design, architecture, technologie, classe CSS, titre etc)
- Erreur coté scraper (mauvaise connexion internet, bug de l’infra)
- Erreur coté site (timeout, site inaccessible)

Confidential - Not for Public Consumption or Distribution

Rendu

Business

- Base de données exploitable des centres commerciaux et magasins associés
- Classification des magasins
- Date d’ouverture et de fermeture

Technique

- Données en CSV
- Extraction des sources des pages obligatoire
- Code source permettant de reconstruire les données
- Pipeline sous forme de script python
- Séparation des étapes en script et données intermédiaires
- Prise en compte des erreurs de scraping
- Github (ou equivalent)

Confidential - Not for Public Consumption or Distribution